



Detección de oportunidades de inversión en contenido a través del estudio del catálogo de Netflix

EQUIPO 7

Gabriel Gómez · Angelo Navarro · Derabin Rodríguez · Nefyasser Tapia

Universidad Tecnológica de Panamá — Maestría en Analítica de Datos

S100 — Introducción a la Ciencia de Datos

<https://github.com/angelonavarrogit/-S100-ANALITICA-DATOS-PROYECTO-FINAL-.git>

Resumen ejecutivo

Netflix enfrenta una desaceleración en el crecimiento de suscriptores y mayor competencia, por lo que necesita identificar dónde diferenciar su oferta de contenido. Usando `netflix_titles.csv` (8,797 títulos tras limpieza), se buscó predecir si un título entra al catálogo fresco (dentro de su primer año de estreno) o de catálogo, a partir de tipo, género, clasificación y país de producción, variables que no determinan el objetivo por construcción, a diferencia del tipo de contenido usado inicialmente. Se comparó un baseline, una regresión logística y un árbol de decisión: ambos superan al baseline (55%) por más de 12 puntos de exactitud (67.3%) y confirman que las series entran más frescas que las películas (67.4% frente a 49.6%).

1. Introducción

Ante la desaceleración del crecimiento de suscriptores y el aumento de la competencia, Netflix enfrenta el desafío de mantener su crecimiento mediante una oferta de contenido atractiva y diferenciada. La expansión de la plataforma depende de identificar segmentos de audiencia y nuevos mercados con potencial. En este contexto, surge la pregunta de negocio: ¿qué géneros y países de producción presentan mayor representación en el catálogo y podrían constituir oportunidades estratégicas de inversión en contenido?

Para responder esto con un modelo predictivo, se planteó inicialmente `type` (Movie/TV Show) como variable objetivo. Sin embargo, tras revisar los datos se identificó que `duration`, `listed_in` y `rating` determinan `type` casi por completo (fuga de datos): un modelo lo acertaría sin haber aprendido ningún patrón real, y además no respondía la pregunta de inversión. Se redefinió entonces la variable objetivo como `es_fresco`: si un título entró al catálogo dentro de su primer año de estreno ("fresco") o después ("de catálogo") — una medida directamente relacionada con la estrategia de diferenciación de contenido (exclusivas nuevas frente a licenciamiento de contenido antiguo).

Pregunta predictiva. ¿Se puede predecir si un título entrará fresco o de catálogo a partir de su tipo, género, clasificación y país de producción?

Hipótesis. Las series entran al catálogo más frescas que las películas. Se contrasta y se confirma con los datos: 67.4% de las series son frescas frente a 49.6% de las películas (17.8 puntos porcentuales de diferencia)



2. Datos y preparación

Fuente: `netflix_titles.csv`, catálogo de Netflix con 8,807 títulos y 12 columnas (tipo, título, director, elenco, país, fecha de incorporación, año de lanzamiento, clasificación, duración, género y descripción).

Limpieza realizada, justificada en cada caso:

- **10 títulos sin `date_added` (0.1%) se descartaron:** sin esa fecha no se puede calcular `es_fresco`.
- **4 valores faltantes y 3 valores inválidos de `rating`** (por un error de desplazamiento de columnas del CSV original, p. ej. "66 min" en vez de una clasificación real) **se imputaron con la moda (TV-MA):** son menos del 0.1% de los datos, imputar evita perder filas por un error mínimo.
- **Country faltante en 831 títulos (9.4%) se mantuvo como categoría propia "Unknown"** en vez de eliminarse, para no perder el resto de la información de esos títulos.
- **Country y `listed_in` son multietiqueta:** se tomó el primer país listado como país principal, agrupando los que están fuera del top 10 en "Otros"; y se generaron columnas binarias para los 15 géneros más frecuentes de `listed_in` (un título puede tener varios en 1).
- **Codificación:** One-Hot Encoding para `type`, `rating` y país agrupado; columnas binarias multietiqueta para género.
- **Escalamiento:** no se aplicó — todas las predictoras finales son categóricas o binarias (0/1).
- **`Release_year` y `año_agregado` se excluyeron explícitamente de las predictoras:** son las columnas con las que se construye `es_fresco`; incluirlas sería fuga de datos en sentido inverso.

Tras la limpieza quedaron **8,797 filas** (una por título) y **42 variables predictoras** (tipo, clasificación, país agrupado y género) para modelar `es_fresco`.

3. Métodos

Se dividió el conjunto en 80% de entrenamiento (7,037 filas) y 20% de prueba (1,760 filas), de forma estratificada según si es fresco (ambos conjuntos conservan el balance real de 55% fresco / 45% de catálogo), con `random_state=42` para que el resultado sea reproducible.

Se compararon tres modelos: un **baseline** (`DummyClassifier`, siempre predice la clase mayoritaria), una **regresión logística** y un **árbol de decisión**. Los hiperparámetros de ambos modelos se ajustaron con `GridSearchCV` y **5 folds de validación cruzada** (`cv=5`): `C` para la regresión logística (rango probado: 0.01 a 100; mejor valor: `C=1`) y `max_depth` para el árbol (rango probado: 2 a 12 y sin límite; mejor valor: `max_depth=12`), eligiendo en ambos casos el valor con mejor exactitud promedio en los 5 folds — nunca mirando el conjunto de prueba durante el ajuste.

Se reportan exactitud, precisión, recall y F1. Como es fresco, está razonablemente balanceado (55%/45%), la exactitud es interpretable directamente; se complementa con F1 para no ignorar el costo de los falsos positivos y falsos negativos.

4. Resultados

Modelo	Exact. train	Exact. test	Precisión train	Precisión test	Recall train	Recall test	F1 train	F1 test
Baseline	0.550	0.550	0.550	0.550	1.000	1.000	0.710	0.710
Regresión logística	0.696	0.673	0.693	0.677	0.804	0.777	0.745	0.723
Árbol de decisión	0.740	0.673	0.748	0.692	0.795	0.731	0.771	0.711

Tabla 1 Métricas por modelo (entrenamiento vs. prueba)

Ambos modelos superan claramente al baseline (55% → 67.3% de exactitud, +12.3 puntos). Entre ellos, la diferencia interesante no está en la exactitud de prueba (prácticamente empatada), sino en la brecha train-test: el árbol tiene una brecha de 6.7 puntos (0.740 → 0.673) frente a solo 2.3 puntos en la regresión logística (0.696 → 0.673) el árbol sobreajusta más, aunque termine generalizando igual de bien en este caso.

Matriz de confusión (prueba), árbol de decisión:

	Predicho: catálogo	Predicho: fresco
Real: catálogo	477	315
Real: fresco	260	708

Tabla 2 Matriz de Confusión

Variables más influyentes: en ambos modelos, `rating_TV-MA` es, por lejos, la más importante — el contenido clasificado para audiencia madura tiende a entrar más fresco. Le siguen el género documental, el tipo de contenido (película vs. serie) y el país (España se asocia a mayor frescura; Japón, a menor — coherente con un catálogo de anime más antiguo y licenciado). Esto indica que género, tipo, clasificación y país sí. Contienen señal real sobre la frescura del catálogo, a diferencia de `type` como objetivo, que no tenía relación real con ninguna pregunta de negocio.

5. Discusión, limitaciones y conclusión

Para cerrar, resumimos las tres preguntas que guían este proyecto — y sus respuestas.

¿Cuál fue la pregunta y la variable objetivo, y qué se responde? La pregunta de negocio planteó la identificación de posibles oportunidades de inversión en contenido diferenciado para Netflix. Para abordar esta cuestión mediante un modelo predictivo, se definió la variable objetivo **es_fresco**, que determina si un título ingresó al catálogo dentro de su primer año de estreno o posteriormente. Los resultados indican que es posible predecir esta característica a partir del tipo de contenido, género, clasificación y país de producción, aunque con una capacidad predictiva limitada. Asimismo, los resultados respaldan la hipótesis de que las series ingresan al catálogo con mayor frescura que las películas, con 67.4% frente a 49.6%, respectivamente. Entre las variables analizadas, **rating_TV-MA** presentó la mayor señal predictiva de frescura, seguido por el género documental y el país de producción, con España asociada positivamente y Japón negativamente

¿Por qué elegimos estos modelos y no otros? La selección del modelo respondió a la necesidad de contar con capacidad predictiva e interpretabilidad. La pregunta necesitaba explicación, no solo predicción: se



requería identificar qué variables explican la frescura, no solo acertar el resultado. La regresión logística y el árbol de decisión exponen esa información directamente, coeficientes e importancia de variables—, encajan sin ajustes con datos categóricos y binarios como los mostrados, y son complementarios: uno lineal, uno no lineal. Modelos más complejos —random forest, SVM, redes neuronales— hubieran sacrificado esa interpretabilidad sin garantía de mejorar la exactitud en un dataset de este tamaño; y k-NN funciona mal con tantas columnas binarias. Se eligió el modelo más simple que responde la pregunta, no el más sofisticado posible.

¿Qué resultados se obtuvieron? Ambos modelos superaron al baseline (55.0%) por más de 12 puntos, llegando a 67.3% de exactitud en prueba, confirmando que hay señal real, no solo azar. Entre ellos, la regresión logística generaliza mejor (brecha train-test de solo 2.3 puntos, frente a 6.7 en el árbol), aunque ambos empaten en exactitud final. Y como límite honesto: 67% no es perfección, casi 1 de cada 3 títulos se clasifica mal, porque las variables predictoras son categorías generales que no capturan cada decisión específica de licenciamiento o marketing detrás de un título. Como línea futura, variables como elenco o popularidad externa podrían mejorar esa señal.

En base a la confección del proyecto, como equipo podemos expresar:

- Uno de los principales desafíos del equipo fue elegir y preparar las variables. La incorporación de un mayor número de variables no garantiza necesariamente un mejor modelo; por el contrario, la eliminación de información con alto nivel de ruido o con potencial de generar fuga de datos contribuyó a construir una solución más consistente y metodológicamente segura.
- La comparación de diferentes algoritmos permitió observar la importancia de la simplicidad y la capacidad de generalización. La regresión logística presentó un comportamiento más consistente entre los conjuntos de entrenamiento y prueba, con una diferencia de 2.3 puntos porcentuales, además de ofrecer un nivel de interpretabilidad adecuado para su comunicación dentro de un contexto organizacional.
- El desarrollo de este proyecto evidenció la necesidad de evaluar de forma sistémica y en equipo cada decisión como: desde la definición de la variable objetivo hasta la interpretación de las métricas. La integración de estos elementos permitió transformar un conjunto de datos sin procesar en un análisis con una aplicación potencial para el contexto de negocio.

Referencias

Bansal, S. (s. f.). Netflix Movies and TV Shows [Conjunto de datos]. Kaggle. Kaggle – Netflix Movies and TV Shows

Declaración de uso de inteligencia artificial

Se utilizaron **ChatGPT, Claude y Gemini** como apoyo en programación, análisis de datos y revisión del código.

La IA fue una herramienta complementaria y **no sustituyó el trabajo ni el criterio del equipo**.

El análisis, desarrollo, ejecución y conclusiones fueron responsabilidad del equipo.

Como alternativas se consideraron la documentación oficial y fuentes técnicas especializadas.